

Métodos para el diseño computacional de fármacos

Andrés Ballesteros

Diseño molecular, simulación e inteligencia artificial

Área Bioinformática – DETEMA – Facultad de Química – Udelar
LSBM – Institut Pasteur de Montevideo



Métodos para el diseño computacional de fármacos

Andrés Ballesteros

Diseño molecular, simulación e inteligencia artificial

Área Bioinformática – DETEMA – Facultad de Química – Udelar
LSBM – Institut Pasteur de Montevideo



¿Cómo elegimos qué moléculas merece la pena estudiar para desarrollar un tratamiento?

Diseño de fármacos y desarrollo de medicamentos

El diseño de fármacos busca moléculas capaces de modificar un proceso biológico de manera útil

01

Descubrimiento

Diseño

Blanco, hit y lead

02

Preclínica

Exposición y
seguridad

03

Clínica I–III

Personas y beneficio.

04

Evaluación

Calidad y evidencia

05

Seguimiento

Seguridad en uso real

Hit: actividad confirmada

Candidato: perfil para avanzar en desarrollo

Lead: serie con potencial de optimización

Afinidad y potencia ayudan. La exposición y la seguridad condicionan el beneficio.

Blancos y mecanismos de acción

Un blanco o diana es una entidad biológica cuya modificación puede producir un efecto terapéutico



Enzima

Acelera una reacción química. **Un inhibidor puede reducir esa actividad.**



Receptor

Reconoce señales. **Un agonista activa una respuesta y un antagonista puede bloquearla.**



Canal o transportador

Controla el paso de sustancias a través de una membrana.



Ligando

Molécula que se une a un blanco. La unión puede modificar su función.

La pregunta terapéutica incluye qué modificar, en qué dirección y dónde.

Integración computacional y experimental

CÓMPUTO (*In Silico*)



Predice actividad y propiedades
Propone estructuras y modificaciones
Prioriza candidatos y experimentos

EXPERIMENTO



Sintetiza y verifica identidad
Mide unión, función y exposición
Evalúa selectividad y toxicidad

Ciclo compartido: diseñar, sintetizar, medir y aprender



Afinidad

Fuerza de unión



Potencia

Concentración para un efecto



Selectividad

Preferencia entre blancos



ADMET

Destino en el organismo y toxicidad

La decisión central

¿Qué molécula sintetizaríamos mañana?


La computadora ordena y prioriza. El laboratorio determina qué hipótesis son viables.

10^6
moléculas



10
experimentos

Diseño en computadora



Aportes

- Prioriza blancos y moléculas
- Compara hipótesis antes de sintetizar
- Integra señales que vienen de escalas distintas

Límites

- Depende de datos y supuestos
- Puede extrapolar fuera de dominio
- Necesita controles y **medición experimental**

1

Identificación
blanco



Tratable y seguro

2

Identificación de
Hits

Señal reproducible

3

Optimización de
Leads



Serie optimizable

4

Estudios
Preclínicos

5


Pruebas Clínicas



Cada resultado puede obligar a volver a una etapa anterior

CADD: el mapa general

Computer-Aided Drug Design



LBDD: aprender de moléculas conocidas

1

Datos

Activos e inactivos

2

Representar

Descriptores o grafos

3

Aprender

Regla o modelo

4

Priorizar


Nuevas moléculas

Pregunta típica

¿Qué compuestos se parecen a patrones asociados con actividad?

Fortaleza: aprovecha datos · Riesgo: extrapolar fuera del dominio

SBDD: diseñar dentro del sitio de unión



Pregunta típica

¿Cómo podría una molécula reconocer y modular este sitio?

Fortaleza: propone un mecanismo 3D · Riesgo: estructura o score incorrectos

¿LBDD o SBDD? La información decide

Conocemos ligandos activos

LBDD

Similitud, farmacóforo, QSAR

Conocemos la estructura 3D

SBDD

Sitio unión, docking, dinámica molecular

Conocemos ambos

Combinación

Modelo, pose, síntesis y ensayo

Conocemos muy poco

Generar evidencia

Biología, cribado y medición

No es una competencia entre métodos: es una decisión condicionada por evidencia

Una situación real combina las dos rutas



Diseñar → sintetizar → medir → aprender

La evidencia nueva vuelve a alimentar ambos modelos

Casos de éxito: el método fue parte de un sistema

1993

Zanamivir

SBDD

Diseño racional sobre neuraminidasa

2019

DRD4

SBDD + VS

Docking de 138 millones; nuevos quimiotipos

2020

Halicina

LBDD + IA

Modelo fenotípico y validación antibacteriana

2021

Nirmatrelvir

SBDD + química

Inhibidor oral de Mpro

Éxito = hipótesis computacional + química + ensayo + desarrollo

01

Blancos y datos

¿Cómo convertimos una enfermedad compleja en una hipótesis tratable?

Una base de datos organiza objetos e identificadores, conserva información sobre su procedencia y permite recuperarlos de manera consistente. La elección depende de la pregunta biológica que queremos resolver.

Bases de datos en CADD y diseño guiado por IA

Bibliotecas químicas

ZINC y PubChem

Buscar, representar y seleccionar moléculas

Actividad y farmacología

ChEMBL, BindingDB y DrugBank

Aprender de ensayos y de fármacos conocidos

Proteínas y estructuras

UniProt, PDB y AlphaFold DB

Identificar blancos y estudiar su geometría

Estructura con afinidad

PDBbind

Relacionar un complejo 3D con una medición

La base adecuada depende de la pregunta y del tipo de evidencia.

ZINC: moléculas para el cribado virtual



Propiedad

UCSF, grupos de John Irwin y Brian Shoichet

¿Qué datos ofrece?

Estructuras 2D/3D, propiedades y referencias a proveedores.

¿Cómo se utiliza?

Bibliotecas para docking, búsqueda de análogos y exploración con IA.

Un catálogo de síntesis bajo pedido no equivale a un inventario físico ni a actividad demostrada.


≈54.900 millones

moléculas 2D enumeradas

ZINC-22, portal consultado 09/09/2026

Ejemplo de consulta

¿Qué moléculas puedo comprar o encargar para evaluar este sitio?



PubChem: información química integrada



Propiedad

NCBI, National Library of Medicine, NIH, Estados Unidos

¿Qué datos ofrece?

Compuestos, datos biológicos (Bioactividad), propiedades FQ y referencias.

¿Cómo se utiliza?

Resolver identidades, recuperar ensayos y reunir datos para modelos químicos.

Un mismo compuesto puede tener varias entradas depositadas y múltiples resultados de ensayo.

124.663.908

registros de compuestos

NCBI Entrez, consulta 09/09/2026

Ejemplo de consulta

¿Cuál es la identidad de esta molécula y qué ensayos la describen?

ChEMBL: moléculas y actividad experimental

Propiedad

Equipo ChEMBL, EMBL-EBI, Reino Unido

¿Qué datos ofrece?

Compuestos, ensayos, blancos, bioactividades, ADMET y datos de fármacos.

¿Cómo se utiliza?

QSAR, relaciones estructura–actividad y modelos supervisados de propiedades.

Ki, Kd, IC50 y respuestas celulares requieren interpretación y curación.


2.921.148

compuestos distintos

ChEMBL 37, publicada 29/05/2026

Ejemplo de consulta

¿Qué compuestos tienen actividad medida frente a este blanco?



DrugBank: fármacos y conocimiento farmacológico



Propiedad

University of Alberta y OMx Personal Health Analytics, Canadá

¿Qué datos ofrece?

Fármacos, blancos, mecanismos, indicaciones, metabolismo e interacciones.

¿Cómo se utiliza?

Reposicionamiento, grafos de conocimiento y análisis de mecanismos.

Incluye categorías experimentales y retiradas. Acceso y reutilización dependen del producto.

20.161

entradas de fármacos de todas las categorías

Estadísticas del portal, consulta 09/09/2026

Ejemplo de consulta

¿Qué mecanismo, blancos e interacciones tiene este fármaco?

UniProt: identidad, secuencia y función de proteínas



Propietario

Consorcio UniProt: EMBL-EBI, SIB y PIR

¿Qué datos ofrece?

Secuencias, funciones, dominios, variantes y referencias cruzadas.

¿Cómo se utiliza?

Identificar blancos y entrenar representaciones o modelos de secuencias.

150.006.383

registros de secuencia en UniProtKB

UniProtKB 2026_03, publicada 02/09/2026

Ejemplo de consulta

¿Qué secuencia, función y variantes corresponden a este blanco?

BindingDB: afinidades proteína–ligando

Propiedad

Universidad de California en San Diego, equipo de Michael Gilson

¿Qué datos ofrece?

Afinidades medidas, estructuras químicas, proteínas, condiciones y referencias.


¿Cómo se utiliza?

Modelos de afinidad, selectividad y relaciones estructura–actividad.

Comparte datos con ChEMBL.

BindingDB

BindingDB Data Structure Overview



1.440.011

compuestos con datos de unión

Descarga 202609, actualizada 30/08/2026

Ejemplo de consulta

¿Qué afinidades se han medido para esta familia de ligandos?

PDBbind: estructura y afinidad en un mismo recurso



Propiedad

Equipo de Renxiao Wang, Fudan University; portal con TopScience

¿Qué datos ofrece?

Complejos 3D asociados a afinidades experimentales y archivos procesados.

¿Cómo se utiliza?

Entrenar y evaluar *scoring*, predicción de afinidad y modelos proteína–ligando.

La estructura, el ligando y la medida deben corresponder. Versiones recientes tienen acceso de pago.

29.001

complejos proteína–ligando

v2025, publicada 08/02/2026 y vigente al corte

Ejemplo de consulta

¿Qué complejos 3D disponen de una afinidad experimental asociada?

PDB: estructuras macromoleculares experimentales

Propiedad

Archivo wwPDB; portales RCSB PDB, PDBe y PDBj.
Universidad de Rutgers y la Universidad de
California en San Diego – EBI-EMBL

¿Qué datos ofrece?

Coordenadas 3D, ligandos, método experimental y validación estructural.

Cómo se utiliza

SBDD, preparación del receptor y entrenamiento de modelos estructurales.

Una entrada es una estructura. Una proteína puede aparecer en muchos complejos.

259.747

estructuras experimentales

RCSB PDB, consulta 09/09/2026



Ejemplo de consulta

¿Hay estructuras experimentales del blanco con ligandos unidos?

AlphaFold DB: estructuras predichas

Propietario

EMBL-EBI y Google DeepMind

¿Qué datos ofrece?

Modelos de monómeros y complejos, secuencias y métricas de confianza.

¿Cómo se utiliza?

Explorar blancos sin estructura experimental y generar hipótesis estructurales.

El índice y las descargas masivas tienen coberturas distintas. La confianza depende del modelo.

261.247.178

modelos estructurales

API de búsqueda, consulta 09/09/2026

Ejemplo de consulta

¿Qué modelo estructural existe y qué regiones tienen mayor confianza?




Tamaño de las bases: corte de septiembre de 2026

Base	Tipo de registro	Cantidad	Versión o consulta
ZINC	Moléculas 2D	≈54.900.000.000	Portal, 09/09/2026
PubChem	Compuestos (CID)	124.663.908	Entrez, 09/09/2026
ChEMBL	Compuestos	2.921.148	v37, 29/05/2026
BindingDB	Compuestos, datos de afinidad	1.440.011	202609, 30/08/2026
DrugBank	Entradas de fármacos	20.161	Portal, 09/09/2026
PDB	Estructuras PDB	259.747	Archivo, 09/09/2026
UniProt	Secuencias UniProtKB	150.006.383	2026_03, 02/09/2026
AlphaFold DB	Modelos indexados	261.247.178	Índice, 09/09/2026
PDBbind	Complejos proteína–ligando	29.001	v2025, 08/02/2026

Consulta común: 09/09/2026.

Menciones por año en la literatura: comparación

PubMed: menciones en descubrimiento de fármacos. 2026 parcial hasta el 9 de septiembre



2000–2025: años completos. 2026: acumulado parcial, sin extrapolar al cierre del año.

Representaciones moleculares


Prop. FQ



Texto/numérico

Ligero

SMILES



Texto químico

Ligero y secuencial

Fingerprint



Subestructuras

Rápido para similitud

Grafo



Átomos y enlaces

Aprendizaje local

Conformero 3D



Geometría

Interacciones espaciales

La representación decide qué diferencias puede aprender el modelo

Representaciones moleculares


Propiedades estructurales y fisicoquímicas comúnmente usadas como filtro

	MW (Da)	PSA (Å ²)	HBA	HBD	cLogP/cLogD	RTB	NAR	Formal charge	References
Lipinski's rule (RO5)	≤500	–	0–10	0–5	≤5	–	–	–	Lipinski et al., 1997
Ghose's rule	160–480	–	–	–	–0.4 to +5.6	–	20–70	–	Ghose et al., 1999
Oprea's drug-like rule	–	–	2–9	0–2	–	2–8	–	–	Oprea, 2000
Walters	200–500	≤120	0–10	0–5	–	0–8	–	–	Walters and Murcko, 2002
Veber's rule	–	≤140	–	–	–	0–10	–	–	Veber et al., 2002
REOS	200–500	–		0–5	–5.0 to 5.0	0–8		–2 to +2	Walters and Namchuk, 2003
Beyond rule of five (bRO5)	≤1,000	<250	<15	≤6	–2 to 10	≤20	–	–	Doak et al., 2014
Congreve's rule (RO3)	<300	–	≤6	≤3	≤3	–	–	–	Congreve et al., 2003
Herbicide-likeness	150–500	–	2–12	<3	≤3.5	<12	–	–	Tice, 2001
Insecticide-likeness	150–500	–	1–18	≤2	0–5	<12	–	–	Tice, 2001
Hao's rule (pesticide-likeness)	≤435	–	≤6	≤2	≤6	≤9	≤17	–	Hao et al., 2011

MW, molecular weight; PSA, polar surface area; HBD, hydrogen bond donor; HBA, hydrogen bond acceptor; RTB, rotatable bonds; NAR, number of aromatic rings.

Representaciones moleculares

Una molécula, cuatro representaciones




Ácido salicílico


A SMILES

O=C(O)c1ccccc1O


B Fingerprint MACCS



C Grafo molecular



D Confórmers 3D



La representación decide qué diferencias puede aprender el modelo

Representaciones de proteínas



Secuencia

Motivos y evolución

Modelos de lenguaje



Estructura

Forma y contactos

Docking y simulaciones



Ensamble

Estados y poblaciones

MD y muestreo



Contexto celular

Expresión y redes

Priorización de blancos

02

LBDD: aprender de ligandos

¿Qué podemos inferir cuando conocemos moléculas y actividades?

Similitud química


Hipótesis

Moléculas parecidas tienden a compartir actividad

Riesgo


Un cambio pequeño puede producir un *activity cliff*

Measure	Expression	Range
Tanimoto/Jaccard coefficient	$\frac{c}{a+b-c}$	0 to 1
Euclidean distance	$\sqrt{a+b-2c}$	0 to N
City-block/Manhattan/Hamming distance	$a+b-2c$	0 to N
Dice coefficient	$\frac{2c}{a+b}$	0 to 1
Cosine similarity	$\frac{c}{\sqrt{ab}}$	0 to 1
Russell-RAO coefficient	$\frac{c}{m}$	0 to 1
Forbes coefficient	$\frac{cm}{ab}$	0 to 1
Soergel distance	$\frac{a+b-2c}{a+b-c}$	0 to 1



Tanimoto alto


$$T_c = \frac{AB}{A + B - AB}$$



$$T_c = \frac{2}{(3+2)-2} = 0.66$$

Farmacóforos

La molécula se abstrae como un patrón espacial de interacciones



Útil cuando ligandos distintos comparten un modo de unión

Donor

Aceptor

Hidrófobo

LM


Aromático

QSAR (relación cuantitativa entre estructura y actividad)

Descriptores

Modelo

Predicción



Activity cliffs

Estructura

Molécula A

Molécula A + CH₃

Pequeña diferencia
estructural, gran
cambio biológico



Actividad

12 nM

8.4 μM

Virtual Screening

El *Virtual Screening* (VS) es una herramienta utilizada en el proceso moderno de descubrimiento de fármacos para identificar nuevos *leads* y moléculas similares a los fármacos para las intervenciones terapéuticas.



<https://doi.org/10.3389/fchem.2021.662688>

03


SBDD: estructura

¿Qué cambia cuando conocemos o predecimos la forma tridimensional del blanco?

¿Cómo obtenemos la estructura de las proteínas?

Cristalografía de rayos X


Permite obtener estructuras en alta resolución a partir de cristales de proteínas.



<https://doi.org/10.1039/D1SC02813H>

Criomicroscopía electrónica (Cryo-EM)


Permite visualizar estructuras proteicas a nivel nanométrico sin necesidad de cristalización.



<https://www.bio.iitb.ac.in/~pbhaumik/>

Espectroscopía de resonancia magnética nuclear (RMN)

Utiliza campos magnéticos para determinar estructuras en solución.





criver.com

¿y si la estructura no está en el PDB?

Modelado por homología

Compara la secuencia de la proteína objetivo con proteínas de estructura conocida para inferir la estructura tridimensional basándose en similitudes.




Threading

Este método alinea la secuencia de la proteína objetivo con estructuras de proteínas de referencia, "encajando" la secuencia en un marco estructural conocido para predecir su conformación.

Métodos basados en IA AlphaFold

Basado en redes neuronales




AlphaFold cambió la disponibilidad estructural

2021

AlphaFold2 amplió el acceso a modelos de proteínas


2024

AlphaFold3 abordó complejos con ligandos, ácidos nucleicos e iones



Las predicciones de AlphaFold3 sobre cómo las proteínas (azul) se unen a ligandos (amarillo) coinciden estrechamente con los datos experimentales (gris).

AlphaFold3 y complejos biomoleculares







Fortalezas

- Predicción conjunta de componentes
- Mejor desempeño en varios *benchmarks*
- Confianza por región e interfaz

Precauciones

- Dependencia del entrenamiento
- Estados biológicos alternativos
- Afinidad todavía difícil

Docking como problema de búsqueda



Traslación
Rotación
Torsiones

Agrupamiento
Clasificación

Generar poses

Ordenar poses

Flexibilidad del receptor

Rígido

Rápido

Un estado

Side chains

Intermedio

Ajuste local

Ensemble


Mayor costo

Estados discretos

Induced fit




Costoso

Cambio acoplado



Más flexibilidad aumenta la precisión y espacio de búsqueda

Funciones de puntuación




Score

Ranking dentro del
protocolo

**No equivale automáticamente a ΔG
experimental**

VS jerárquico



Caso de estudio: inhibidores de α -glucosidasa

LBDD convencional y cribado virtual

Objetivo del estudio

Identificar nuevos inhibidores de α -glucosidasa a partir de una serie conocida de xantonas y una biblioteca comercial.

51 Estructuras tipo xantona para entrenamiento y prueba


Métodos convencionales

Farmacóforo basado en ligandos

3D-QSAR mediante PLS


Cribado de la biblioteca *Maybridge*

Docking con Glide y dinámica molecular



Flujo del VS

De ligandos conocidos a evaluación experimental



51 xantonas

Alineamiento 3D

Farmacóforo

3D-QSAR

Biblioteca Maybridge

Docking con
Glide

MD + bioensayo

El farmacóforo y el 3D-QSAR reducen la biblioteca; el docking examina la pose y el ensayo confirma la actividad

Resultados disponibles

51


Xantonas iniciales

8

Compuestos seleccionados
para evaluación biológica

4

Compuestos activos
estudiados mediante MD



Caso 1

DRD4 y cribado ultragrande

receptor dopaminérgico D4, o DRD4

138 M moléculas

81 quimiotipos nuevos

30 activos submicromolares

180 pM agonista optimizado

04

Dinámica y energía


¿Qué cambia cuando tratamos la proteína como un conjunto de estados?

Docking y dinámica molecular

Ejemplo: metanol (CH_3OH) en un sitio de unión

DOCKING MOLECULAR


Una pose seleccionada



Metanol: C gris O rojo H blanco

DINÁMICA MOLECULAR

La misma molécula en distintos tiempos



El solvente y los residuos del sitio también cambian de posición

Resultado

Pose + puntuación

Qué describe

Una configuración

Resultado

Trayectoria temporal

Qué describe

Movimiento y cambios
en las interacciones

El docking sugiere una pose del metanol. La dinámica molecular evalúa cómo cambia con el tiempo

Energía libre de unión


Afinidad

ΔG°

Kd

Más favorable

Menor Kd



La relación termodinámica es exacta. La estimación computacional conserva incertidumbre.

LBDD - *p*-Quinones - Chagas


Research paper

Mode of action of *p*-quinone derivatives with trypanocidal activity studied by experimental and *in silico* models




Andres Ballesteros-Casallas^{a,b,1}, Cristina Quiroga^{c,1}, Cecilia Ortiz^c, Diego Benítez^c, Pablo A. Denis^d, David Figueroa^a, Cristian O. Salas^e, Jeanluc Bertrand^e, Ricardo A. Tapia^e, Patricio Sánchez^e, Gian Pietro Miscione^{a,*}, Marcelo A. Comini^{c,*}, Margot Paulino^{b,*}


I




III




II



IV







Laboratorio húmedo



Bioactividad

Series	Compound ^a	<i>T. brucei</i>	Macrophages	<i>T. cruzi</i>	<i>L. infantum</i>
		EC ₅₀ (μM) and SI ^b	CC ₅₀ (μM) and/or % viability	% Viability or EC ₅₀ (μM) and SI ^b	% Viability or EC ₅₀ (μM) and SI ^b
I	1	5.2 / ~10	~50 (57%) ^c	-	-
	2	3.8 / < 13	< 50 (37%) ^c	-	-
	3	5.5 / < 9	< 50 (24%) ^c	-	-
	4	4.3 / ~14	~50 (63%) ^c	-	-
	5	4.6 / ~11	~50 (49%) ^c	-	-
II	6	2.7 / 44	118	88 % ^d	129 % ^d
	7	38.0 / 2	59	-	-
	8	2.9 / 13	37	-	-
	9	0.9 / 63	57	0.8 / 71	102 % ^d
III	10	1.3 / < 8	< 10 (0%) ^d	-	-
	11	1.5 / 40	61	78 % ^d	91 % ^c
	12	1.8 / < 6	< 10 (40%) ^d	-	-
	13	0.5 / < 22	<10 (17%) ^d	-	-
	14	1.8 / 43	78	1.1 / 71	90 % ^c
IV	15	5.0 / < 2	< 10 (5%) ^d	-	-
	16	2.3 / < 4	< 10 (21%) ^d	-	-
	17	1.6 / < 6	< 10 (10%) ^d	-	-
	18	3.3 / 14	46	-	-
	19	1.9 / < 5	< 10 (0.5%) ^d	-	-
Nifurtimox		5.3 / 19	100	0.7 / 142	137% (at 20 μM)
Benznidazole		-	-	2.2	-
Amphotericin B		-	9.0	-	0.035 / 257
Miltefosine		-	50	-	38.2 / ~1

Hits




4 hits para *T. Brucei* (6,9,11,14)

2 hits para *T. Cruzi* (11,14)

Series	Compound ^a	<i>T. brucei</i>	Macrophages	<i>T. cruzi</i>	<i>L. infantum</i>
		EC ₅₀ (μM) and SI ^b	CC ₅₀ (μM) and/or % viability	% Viability or EC ₅₀ (μM) and SI ^b	% Viability or EC ₅₀ (μM) and SI ^b
I	1	5.2 / ~10	~50 (57%) ^c	-	-
	2	3.8 / < 13	< 50 (37%) ^c	-	-
	3	5.5 / < 9	< 50 (24%) ^c	-	-
	4	4.3 / ~14	~50 (63%) ^c	-	-
	5	4.6 / ~11	~50 (49%) ^c	-	-
II	6	2.7 / 44	118	88 % ^d	129 % ^d
	7	38.0 / 2	59	-	-
	8	2.9 / 13	37	-	-
	9	0.9 / 63	57	0.8 / 71	102 % ^d
	10	1.3 / < 8	< 10 (0%) ^d	-	-
III	11	1.5 / 40	61	78 % ^d	91 % ^e
	12	1.8 / < 6	< 10 (40%) ^d	-	-
	13	0.5 / < 22	< 10 (17%) ^d	-	-
	14	1.8 / 43	78	1.1 / 71	90 % ^e
	15	5.0 / < 2	< 10 (5%) ^d	-	-
IV	16	2.3 / < 4	< 10 (21%) ^d	-	-
	17	1.6 / < 6	< 10 (10%) ^d	-	-
	18	3.3 / 14	46	-	-
	19	1.9 / < 5	< 10 (0.5%) ^d	-	-
Nifurtimox		5.3 / 19	100	0.7 / 142	137% (at 20 μM)
Benznidazole		-	-	2.2	-
Amphotericin B		-	9.0	-	0.035 / 257
Miltefosine		-	50	-	38.2 / ~1


Cálculos QM para obtener descriptores



6-311 +G** basis set on all atoms and the M05-2X1 functional, using the implicit solvent model SMD

ΔG semiquinona ($Q^{\cdot-}$)
 ΔG hidroquinona (QH_2)
HOMO, LUMO, SUMO energías

QSAR-2D
QSAR-3D
Correlaciones





Busqueda Computacional de blancos moleculares

RVS, Target Fishing, Inverse Docking



Synthesis of 2,7-diarylpyrazolo [1,5-a] pyrimidine derivatives with antitumor activity. Theoretical identification of targets

Andrés Ballesteros-Casallas^{a,b}, Margot Paulino^{b,*}, Pietro Vidossich^{a,e}, Carol Melo^c, Elizabeth Jiménez^c, Juan-Carlos Castillo^{d,f}, Jaime Portilla^d, Gian Pietro Miscione^{a,**}



Busqueda Computacional de blancos moleculares

RVS, Target Fishing, Inverse Docking




05

Inteligencia artificial

¿Qué cambió y qué sigue dependiendo de la física y el experimento?

¿Qué significa AI-driven drug design?



La medición actualiza el modelo y cambia la próxima decisión


IA-driven no significa 'IA sola': significa un ciclo de decisión guiado por aprendizaje

Dónde interviene la IA en CADD

Etapas del CADD	Enfoque convencional	 Aporte de la IA
Representación molecular	Descriptores y <i>fingerprints</i> definidos previamente	Representaciones aprendidas desde SMILES, grafos y estructuras 3D
Predicción de propiedades	Un modelo para cada propiedad	Modelos multitarea y preentrenados
Exploración del espacio químico	Búsqueda y puntuación de bibliotecas predefinidas	Generación de moléculas y priorización simultánea
Modelado estructural	Estructuras experimentales, modelado y docking	Predicción de estructuras, complejos, poses y afinidades
Selección experimental	Selección manual en rondas sucesivas	Aprendizaje activo: selecciona los compuestos más informativos


La IA puede intervenir en todo el ciclo: representa, predice, diseña y guía el siguiente experimento

Mapa de la IA en descubrimiento




DOI: 10.1039/d5dd00549c

IA en CADD



IA en CADD




Summary of methods and datasets used in protein-ligand binding pose prediction/generation models.

Name	Algorithms	Training dataset	Test dataset
DiffDock [24**]	Diffusion	PDBbind	Holo structures from PDBbind, Apo structures from ESMFold [23]
KarmaDock [25]	GNN, MDN	PDBbind	CASF-2016, DEKOIS2.0, APOBind coreset [26]
CarsiDock [27]	Transformer, MDN	PDBbind	CASF-2016, PoseBusters, APObind-core [26], PDBbind-CrossDocked-set, DEKOIS2.0
Uni-Mol [28]	Transformer	PDBbind	CASF-2016
EquiBind [29]	GNN, transformer	PDBBind (before 2019)	PDBBind (post-2019)
E3Bind [30]	Transformer, GNN	PDBBind (before 2019)	PDBBind (post-2019)
SufDock [31]	Transformer, diffusion	PDBBind (before 2019)	PDBBind (post-2019), PoseBusters, Astex diverse set [32], DEKOIS2.0
NeuralPLexer [33]	GNN, diffusion	PL2019-74k [33]	PDBBind (post-2019)
AlphaFold3 [2**]	Transformer, diffusion	RCSB PDB (before 2021/09/30)	PoseBusters
RoseTTAFold-all-atom [34**]	Transformer	RCSB PDB	PoseBusters

Cofolding

AlphaFold3, Boltz-1/Boltz-1x, NeuralPLexer y RoseTTAFold All-Atom

co-plegado *Boltz-1x*




Secuencias y
componentes

Modelo conjunto


Complejo 3D

IA in CADD - QSAR




Active learning

El **Aprendizaje Activo (AL)** es un proceso dinámico e iterativo de retroalimentación que identifica y selecciona de manera eficiente los datos más valiosos dentro del espacio químico para ser etiquetados o evaluados.




Active learning - Aplicaciones

The application of active learning in the field of drug discovery




VS - ML

Representación esquemática del VS



- Los ligandos de MAO seleccionados de la base de datos ChEMBL se anclan y se generan las hipótesis farmacofóricas de las mejores moléculas de acoplamiento.
- Paralelamente, los fingerprints y los descriptores de los compuestos se usan para entrenar modelos de aprendizaje automático, lo que permite predecir valores de actividad y puntuaciones de *docking*.
- Los farmacóforos y los modelos de unión se utilizan para identificar los compuestos más prometedores del ZINC

V-SYNTHES2: cribado virtual de fármacos en bibliotecas químicas de escala masiva




3,8 M

dockings aproximados para representar un espacio de 36 mil millones

- Enumeración jerárquica
- Selección geométrica de fragmentos
- Validación prospectiva en dos blancos

Halicina: aprendizaje profundo y reposicionamiento



2.335

moléculas en el conjunto inicial

>107 M

moléculas evaluadas virtualmente

El modelo priorizó un candidato inesperado que después se validó

Cinco reglas para interpretar resultados

- 1 Cada método responde una pregunta concreta
- 2 El *score* ordena hipótesis dentro de un protocolo
- 3 La incertidumbre debe acompañar la predicción
- 4 Física, IA y experimento funcionan mejor conectados

Preguntas

