


Modelos de Lenguaje de Proteínas y Embeddings Proteicos



Del alfabeto de 20 letras al diseño *de novo*

Ignacio Ferrés

Universidad ORT Uruguay


Mapa de la clase

Módulo	Qué se llevan
1. Leer una proteína como si fuera un texto	Un vocabulario compartido
2. Embeddings estáticos	Qué es un vector y de dónde sale: word2vec y ProtVec
3. Los vectores y el contexto	El vector deja de ser fijo: ELMo y SeqVec
4. Llega la atención	Qué es un transformer y por qué ganó
5. La estructura emerge	El modelo predice estructura a partir de la secuencia primaria
6. La forma se vuelve texto	Comparar y anotar estructura con modelos de lenguaje
7. Secuencia, estructura y función	El salto generativo: ESM3
8. Casos de aplicación	Cuatro casos reales, uno de ellos local
Cierre	Los límites: la mesada sigue mandando

Leer una proteína

como si fuera un texto

Una proteína es texto



INGENIERÍA

Alfabeto de ~27 letras → palabras → oraciones

BIOTECNOLOGÍA

20 aminoácidos → motivos → proteínas

La misma cadena de símbolos se puede leer en cuatro niveles:

Nivel biológico	Equivalente en lenguaje	Qué captura
Estructura primaria	Texto plano	El orden de los símbolos
Estructura secundaria	Morfología	Patrones locales
Estructura terciaria	Sintaxis y gramática	Elementos <i>distantes</i> que se relacionan
Función biológica	Semántica	El significado global

Quando el texto cambia

Si una proteína es texto, entonces podemos hablar de **ediciones al texto**. Estas son las tres que importan, y *no* son equivalentes entre sí.

1 · MUTACIÓN PUNTUAL

MKV **L** AG
↓
MKV **F** AG

Cambia **una letra**. El resto de la frase queda igual: es el «error tipográfico».

Efecto: puede ser *silencioso* o destruir la función.

2 · PERMUTACIÓN CIRCULAR

MKVAG
↓
AGMKV

Se corta y se **reordena**: las mismas letras, otro orden.

Solo es inocua si los extremos N y C ya estaban *juntos en el espacio*.

3 · HOMOLOGÍA

humano: MKVLAG
ratón: MK**I**L**S**G

No es un error: es **divergencia** desde un ancestro común.

El texto cambió y la función se conservó.

Por qué esto importa para un modelo de lenguaje: los tres casos producen secuencias parecidas, pero significan cosas distintas. Una mutación suele cambiar la función; una permutación circular bien ubicada, no; dos homólogos pueden diferir en muchas letras y hacer *lo mismo*.


Un modelo que solo cuente letras no distingue estos casos. Uno que aprenda **contexto** —el resto de la frase y su estructura— sí. Esa es la diferencia entre ProtVec y todo lo que viene después.

Breve Historia de los LLMs

y de los modelos de lenguaje de proteínas

La familia de modelos


De *k*-meros al diseño generativo de proteínas. La misma idea, dos disciplinas: vamos a ir completando esta línea **a medida que avance la clase**.



El patrón que vamos a ver: cada salto de esta línea agrega *contexto*. Primero una letra, después su entorno, después la secuencia entera, después la forma — y finalmente la función.

La familia de modelos

De *k*-meros al diseño generativo de proteínas. La misma idea, dos disciplinas: vamos a ir completando esta línea **a medida que avance la clase**.



De las reglas y los alineamientos a los **vectores estáticos**: una palabra, un vector.

El patrón que vamos a ver: cada salto de esta línea agrega *contexto*. Primero una letra, después su entorno, después la secuencia entera, después la forma — y finalmente la función.

¿Qué es un *embedding*?

La traducción literal sería «**incrustación**»: el concepto se *incrusta* en un espacio de muchas dimensiones. Pero se usa «**representación vectorial**», que describe mejor lo que hace: *representar* algo con una lista de números.

PASO 1 · CADA ÍTEM RECIBE UNA POSICIÓN

Un modelo solo manipula **números**. Una app de recetas tiene 5.000 comidas: cada una necesita su lugar.




Figura 1 (Google). Cinco de las 5.000 comidas del conjunto de datos.

PASO 2 · ONE-HOT: UN 1 Y EL RESTO 0S

Cada comida es un vector de **5.000** posiciones: un **1** en la propia y **0** en las otras 4.999.




Figura 2 (Google). El **1** se mueve con cada comida: nunca dicen «parecido».

El problema: todos los **1s** están a la misma distancia, así que borscht y shawarma quedan *igual de lejanos* que borscht y pizza. Y son vectores de 5.000 números casi todos **0s**: enormes y vacíos. El *embedding* es lo que viene después: comprime eso y aprende qué se parece a qué.

Cómo se entrena: de 1s y 0s a relaciones

1 Tapar una palabra


Como te gustan los panqueques,
te recomendamos los ?

2 Adivinar

Antes de entrenar, al azar: **borscht** ✖
Tras millones de intentos: **crepes** ✔

3 Ajustar los pesos


El error es la señal: las conexiones que llevaron al error se debilitan y las que acercaban a la respuesta se refuerzan.



Esquema: las conexiones rojas llevan al error; las verdes acercan a la respuesta. No son datos reales de entrenamiento.

El salto: *one-hot* solo sabe *contar* — cuántos 1s y dónde. El *embedding* sale de millones de intentos como este: cada comida termina con una **posición**, y quedar cerca o lejos *significa* algo.

Una dimensión imaginaria: la «sandwichicidad»



Cada comida tiene una **posición** en este eje. La sopa y la pizza quedan lejos; el *hot dog* y el *shawarma*, cerca.

Y si agregamos otra dimensión...

Un eje más y el mapa se vuelve un plano. Ahora cada comida tiene *dos* coordenadas.

CADA EJE CAPTURA UN RASGO


Un eje mide «sandwichidad», el otro «postreidad». Son **rasgos**, no categorías cerradas.

LA POSICIÓN ES EL SIGNIFICADO

Dos comidas parecidas quedan **cerca**. La distancia ya es información.

NADIE DISEÑA LOS EJES

En un embedding real hay **cientos o miles** de dimensiones así. Las descubre el modelo, no una persona.



Con dos ejes, cada comida tiene una posición. Agregar dimensiones agrega rasgos, no desorden.

La progresión: una dimensión ordena en una línea; dos arman un mapa; N dimensiones permiten comparar parecidos que ningún eje solo podría describir.

Relaciones semánticas *fijas* = direcciones

En un espacio de embeddings, una **relación** es una *dirección*. Y son **fijas**: la misma palabra ocupa siempre el mismo lugar, aparezca donde aparezca.

GÉNERO

rey → reina

La misma distancia que hombre → mujer.

TIEMPO VERBAL

caminando → caminó


El mismo salto que nadando → nadó.

PAÍS → CAPITAL

Chile → Santiago

Doce países, la misma dirección.

La idea: el modelo nunca vio la palabra «capital». Aprendió la *dirección* que separa un país de su capital, y esa dirección sirve para todos.



Tres planos de un espacio de embeddings. Las flechas de cada plano son **paralelas**: esa dirección es la relación.

Word2vec · el origen de todo

Mikolov et al. (2013), Google. Antes de las proteínas, la idea se inventó para el **lenguaje natural**: convertir cada palabra en un vector.

ERA UN TRUCO, NO UN OBJETIVO

Nadie quería predecir palabras: eso es un **problema ficticio**. Se inventó *solo* como excusa para obligar a la red a aprender algo útil en el camino. **La predicción se descarta; los vectores se quedan.**

1

La tarea inventada

Tapa una palabra y trata de *adivinarla* por las que la rodean.

2

Lo que aprende

Para acertar, la red *tiene* que descubrir qué palabras van juntas.

3

El premio real

Se tira la salida y se guardan los **pesos internos**: eso es el embedding.

DOS FORMAS DE PLANTEAR EL JUEGO

- **CBOW** — tapa el medio, adivina por el contexto. Rápido, mejor con la *forma*.
- **Skip-gram** — al revés: con una palabra, adivina qué la rodea. Más lento, mejor con el *significado*.

POR QUÉ FUERON NOTICIA

6.000 millones de palabras del corpus Google News, vocabulario de **1 millón**, y entrenadas **en menos de un día**: la red no tiene capa oculta, y esa simpleza es lo que permitió la escala.

La conexión con la clase: cambiá «palabras» por «*k*-meros» y «oraciones» por «secuencias», y ya tenés la familia entera —ProtVec, SeqVec, ProtT5— resolviendo ese mismo truco, cada vez mejor.

Word2vec · la aritmética del significado

Ya vimos que una relación es una *dirección* (diapositiva 12). Word2vec fue el modelo que lo demostró **a escala**: lo hizo con 6.000 millones de palabras.

LO QUE TRAJO WORD2VEC

- Las relaciones **emergen** del entrenamiento: nadie etiqueta «género» ni «capital». No hay que enseñárselas.
- Y valen para **pares que nunca vio juntos**: la dirección se generaliza.

DE 50.000 NÚMEROS A 300

1 0 0 ... 0	0,2 -1,4 0,8 ...
disperso	denso
50.000 posiciones	100–300
casi todo ceros	todos con valor

Misma palabra, **167 veces menos** números (50.000 ÷ 300), y ahora con información.

DOS ARQUITECTURAS, DOS TALENTOS

Modelo	Significado	Forma
CBOW	24 %	64 %
Skip-gram	55 %	59 %

Acierto en el test de relaciones (Mikolov et al., 2013, Tabla 3).

Dos preguntas sobre la misma red: Skip-gram *más que duplica* a CBOW en significado (55 % vs 24 %), pero pierde en forma. Por eso la familia de proteínas se apoya en Skip-gram: en una proteína importa el **significado**, no la forma superficial.

Y el vector sale de la nada: no hay una capa oculta que «calcule» — la matriz de pesos es la tabla. Buscar una palabra es buscar su fila. Por eso es tan barato.

Mikolov et al. (2013), arXiv:1301.3781 · Tabla 3 (pág. 6)

ProtVec · el punto de partida

La primera traducción de la idea de **word2vec** a proteínas (Asgari & Mofrad, 2015).

CÓMO FUNCIONA

- Parte la secuencia en **3-meros**: MKV , KVL , VLA ...
- Cada 3-mero es una «palabra»
- Aprende un vector por palabra

La secuencia se vuelve una bolsa de palabras. Es la misma jugada que en lenguaje natural: contar vecinos frecuentes.

Su límite: el vector de MKV es siempre el mismo, aparezca donde aparezca. **No hay contexto.** Y la ventana de 3 residuos es demasiado corta para ver estructura.

Original Sequence

(1) $\vec{M}$ (2) $\vec{A}$ (3) $\vec{F}$ SAEDVLKEYDRRRRMEAL..

Splittings

$\left\{ \begin{array}{l} 1) \text{ MAF, SAE, DVL, KEY, DRR, RRM, ..} \\ 2) \text{ AFS, AED, VLK, EYD, RRR, RME, ..} \\ 3) \text{ FSA ,EDV, LKE, YDR, RRR, MEA, ..} \end{array} \right.$

La misma secuencia, partida en tres marcos superpuestos. Cada 3-mero es una «palabra».

Asgari & Mofrad (2015). *Continuous Distributed Representation of Biological Sequences*. PLoS ONE 10(11):e0141287

El contexto entra en escena



De un vector fijo por palabra a un vector que **depende de sus vecinos**.

El contexto entra en escena



De un vector fijo por palabra a un vector que **depende de sus vecinos**.

ELMo · la arquitectura que hace posible el contexto

Peters et al. (2018), Allen AI. SeqVec no la inventa: la *aplica* a proteínas. Vale la pena entender cómo funciona por dentro.

DOS LSTM, ENTRENADAS JUNTAS

- Una pasada **hacia adelante**, otra **hacia atrás**
- Se entrenan **de forma conjunta** (se comparten la capa de entrada y la de salida)
- Pero cada dirección tiene sus **propios parámetros** de LSTM

EL VECTOR SE *CONCATENA*

En cada posición se pegan las dos direcciones: `[→ h ; ← h]`. No es una sola pasada que ve todo, son **dos recorridos unidos al final**.

LO QUE LO HIZO DISTINTO

No usa solo la última capa. Combina **todas** con pesos que aprende cada tarea: las capas bajas capturan *sintaxis*, las altas *semántica*.

LOS NÚMEROS

- **2 capas** de biLSTM por dirección
- **4096** unidades, proyección a **512**
- **5 representaciones** por token (entrada + 2 adelante + 2 atrás)
- Entrada **por caracteres**, no por palabras

Entrada por caracteres: como lee letra por letra, ELMo puede representar palabras que *nunca vio* en el entrenamiento. En proteínas esto es todavía más natural: el «vocabulario» son 20 letras.

El puente a proteínas: cambiá las palabras por aminoácidos y el resto del mecanismo funciona igual. Eso es exactamente lo que hace SeqVec en la slide siguiente. Peters et al. (2018), *Deep contextualized word representations*, arXiv:1802.05365

SeqVec · aparece el contexto

Heinzinger et al. (2019) aplican la arquitectura de **ELMo** a proteínas — el mismo autor que después haría ProtT5.

Ya no hay 3-meros

Se lee la secuencia **completa**.

El vector depende del entorno

Cada residuo mira a sus **vecinos**.

Bidireccional

Dos pasadas, una por sentido (ELMo) — *no masked*.





Figura 2 del paper. Proyección *t-SNE*: **arriba** sin entrenar, **abajo** tras entrenar; color por localización celular (izq.) y por membrana (der.).

Lo que muestra: los embeddings *sin entrenar* ya agrupan proteínas por función — una señal que el modelo **nunca recibió**. Entrenarlo solo mejora la separación. · Heinzinger et al. (2019), BMC Bioinformatics 20:723

SeqVec · el contexto se nota

La misma comparación de siempre: **misma tarea, misma secuencia de entrada**. Lo único que cambia es cómo se representa cada residuo.



A · Estructura secundaria

SeqVec queda cerca de los mejores métodos, *sin* usar alineamientos.

D · Membrana

Salta de 77,6 (ProtVec) a 92,3 (DeepLoc con SeqVec).

SeqVec (barras oscuras) frente a ProtVec y métodos clásicos, en cuatro tareas. El contexto se traduce en rendimiento.

MÓDULO 4 · LLEGA LA ATENCIÓN

Llega la atención



De leer en orden a mirar **todo a la vez**. El salto que habilita la escala.

MÓDULO 4 · LLEGA LA ATENCIÓN

Llega la atención



De leer en orden a mirar **todo a la vez**. El salto que habilita la escala.

El Transformer · la atención lo cambia todo

Vaswani et al. (2017), Google. La arquitectura que está detrás de *todos* los modelos que siguen —en texto y en proteínas— y también de los LLMs actuales.

EL PROBLEMA QUE RESOLVIÓ

- Los modelos previos (RNN, LSTM) leían **en orden**, símbolo por símbolo
- Eso los hacía **lentos**: no se podían paralelizar
- Y olvidaban lo **lejano**: la posición 5 y la 500 apenas se conectaban

LA IDEA: SELF-ATTENTION

Cada posición **mira a todas las demás a la vez** y decide cuánto le importa cada una. Sin leer en orden, sin recurrencia.

Distancia entre dos posiciones cualesquiera: **un solo paso** (en una RNN eran hasta n pasos).

Q · K · V

Cada símbolo se proyecta en *consulta*, *clave* y *valor*. El parecido entre consulta y clave decide cuánto se mezcla cada valor.

Multi-head (8 cabezas)

Ocho atenciones en paralelo, cada una mirando un tipo de relación distinto. Se concatenan al final.

Posición explícita


Como no hay orden implícito, la posición se *suma* al vector: senos y cosenos de distinta frecuencia.

Por qué nos importa: el Transformer no sabe de biología, solo de *secuencias y relaciones a distancia*. Es exactamente el problema de la estructura terciaria: posiciones lejanas en la cadena que están cerca en el espacio.

Vaswani et al. (2017), *Attention Is All You Need*, arXiv:1706.03762 · 6 capas, 512 dim., 8 cabezas

Las tres formas de leer una secuencia

La misma secuencia **MLVAGRR**, tres maneras de procesarla. Cambia qué puede ver cada residuo — y por lo tanto para qué sirve el modelo.



Las tres arquitecturas sobre la misma secuencia. El residuo naranja es el que se predice.

A • AUTORREGRESIVA

Una sola dirección: $p(x_t | x_1 \dots x_{t-1})$. Solo mira lo anterior.

Para qué sirve: *generar* — inventar secuencias nuevas. ProtGPT2, ProGen

B • BIDIRECCIONAL

Dos pasadas *independientes* que después se **concatenan**. Ve izquierda y derecha, pero en dos recorridos separados.

Para qué sirve: *etiquetar cada residuo* — estructura secundaria, accesibilidad al solvente, sitios activos. ELMo, SeqVec

C • MASKED

Toda la secuencia a la vez; se tapa un residuo y se predice. Cada posición ve **todo** el resto en una sola pasada.

Para qué sirve: *representar* — embeddings de alta calidad para clasificar. BERT, ESM, ProtBERT

¿Querés *entender* una proteína que ya existe? → **C** (o **B** si te importa cada residuo). ¿Querés *inventar* una nueva? → **A**.

Por qué la atención cambió todo

RNN / LSTM

- Leen **de a un elemento**
- Lo lejano se **desvanece**
- **No se paraleliza**

TRANSFORMER

- Mira **toda la secuencia**
- Lo lejano en 1D puede estar **cerca en 3D**
- **Se paraleliza** → escala

Un residuo en la posición 5 y otro en la 300 pueden estar pegados en la estructura plegada. La atención los conecta *directamente*.

Lo que sigue: los embeddings ya los vimos al principio (slides 8–12) y eran *fijos*. La atención es lo que permite que dejen de serlo: ahora el contexto puede **ajustar** el vector de cada residuo. Veamos qué cambia.

El mismo símbolo, dos significados

«Chile es un país»



«El chile es picante»



«Un señor sentado
en un banco»




Un **embedding fijo** no puede distinguir estos significados. Uno **contextual**, sí.


Y lo mismo pasa con un aminoácido: su comportamiento depende de *quién lo rodea* en la cadena.

El señor está sentado en un *banco* — pero no en el mismo sentido que un banco de plaza.

El mismo problema, en proteínas





Cada paso tapa un sector distinto: así aprende el modelo.



El modelo **reescribe** el vector de cada residuo según toda la secuencia.

Las **últimas capas ocultas** reescriben el vector de cada aminoácido según toda la secuencia. Entra un símbolo; sale un vector *situado* — y la forma deja de ser un dibujo aparte.



El mismo problema, en proteínas



El modelo **reescribe** el vector de cada residuo según toda la secuencia.

Las **últimas capas ocultas** reescriben el vector de cada aminoácido según toda la secuencia. Entra un símbolo; sale un vector *situado* — y la forma deja de ser un dibujo aparte.



El mismo problema, en proteínas



El modelo **reescribe** el vector de cada residuo según toda la secuencia.

Las **últimas capas ocultas** reescriben el vector de cada aminoácido según toda la secuencia. Entra un símbolo; sale un vector *situado* — y la forma deja de ser un dibujo aparte.

El mismo problema, en proteínas



El modelo **reescribe** el vector de cada residuo según toda la secuencia.

Las **últimas capas ocultas** reescriben el vector de cada aminoácido según toda la secuencia. Entra un símbolo; sale un vector *situado* — y la forma deja de ser un dibujo aparte.

Cómo se extrae el vector de una proteína



Dos formas de usar la salida: *por residuo* (predecir posición por posición, como la estructura secundaria) o *promedio* (clasificar la proteína entera, como su localización subcelular).

El vocabulario no es el alfabeto. La biología tiene **20** aminoácidos, pero ESM-2 usa **33** tokens: los 13 extra son símbolos de control — inicio, fin, relleno, la *máscara*, **X** para desconocidos y aminoácidos ambiguos.

Los números son inventados: en ESM-2 cada vector tiene **1280** números, no 8. Verificado en facebook/esm2_t33_650M_UR50D: 1280 dimensiones, 33 capas.

ProtT5 y ProtBERT · llega el Transformer a las proteínas

El proyecto **ProtTrans** (Elnaggar et al., 2021) entrena transformers a gran escala sobre secuencias.


DOS FAMILIAS, DOS OBJETIVOS

- **ProtBERT** — solo *encoder*, objetivo *masked*
- **ProtT5** — *encoder-decoder*, objetivo de *denoising*

LO QUE DEMOSTRÓ

- Un PLM **sin MSA** ni información evolutiva explícita
- Iguala o supera a los métodos clásicos
- Sus embeddings alimentan **clasificadores simples**

Sin alineamientos. La información evolutiva que los métodos clásicos sacaban de un MSA, el modelo la aprende de haber visto millones de secuencias.



ProtT5 y ProtBERT frente a ESM-1b, DeepLoc y métodos clásicos en localización subcelular.

Elnaggar et al. (2021), *ProtTrans*, IEEE TPAMI ·

huggingface.co/Rostlab

MÓDULO 5 · LA ESTRUCTURA EMERGE

La estructura emerge del entrenamiento



Nadie le enseñó 3D, y sin embargo la atención **la encuentra**.

MÓDULO 5 · LA ESTRUCTURA EMERGE


La estructura emerge del entrenamiento



Nadie le enseñó 3D, y sin embargo la atención **la encuentra**.


ESM-1b · la estructura *está adentro*

Rives et al. (2021). El hallazgo que cambió la percepción de estos modelos: **nadie le enseñó estructura**, y sin embargo quedó codificada.



La atención de un residuo apunta a residuos *lejanos* en la secuencia pero **cercanos en el espacio**. Es lo que *permite* que se conecten.

El **mapa de contactos** que se recupera de ESM-1b: azul son aciertos, rojo falsos positivos, gris el mapa real. Abajo de la diagonal, ESM-1b; arriba, el método clásico CCMpred.




Nota: la información *está* en las representaciones, pero para leerla hace falta una **sonda entrenada** —una proyección lineal o un clasificador chico. Nadie le pasó un solo contacto durante el entrenamiento: los aprendió de rellenar máscaras. Es el mismo patrón del caso de Puglia: *embeddings congelados + un clasificador simple*.

Rives et al. (2021). *Biological structure and function emerge from scaling unsupervised learning*. PNAS 118(15) · Figura 5 ·


huggingface.co/facebook/esm1b_t33_650M_UR50S

ESM-2 · más escala, más estructura

Lin et al. (2023). La misma receta que ESM-1b, llevada al extremo: **8 millones** a **15 000 millones** de parámetros. La perplejidad baja de **10,45** a **6,37** (el azar sería ~20), y la precisión de contactos mejora en *todos* los tramos.



La arquitectura. La secuencia entra al **ESM-2** (preentrenado con máscaras), pasa por el *Folding Trunk* y el *Structure Module*, y sale la estructura con su confianza. El *recycling* vuelve a pasar el resultado: se refina sobre su propio borrador.



vs. AlphaFold 2. Turquesa ESMFold, verde AlphaFold 2. Predicen casi lo mismo *sin* que ESMFold vea alineamientos.



vs. el PDB. Turquesa ESMFold, marrón la estructura *experimental*. Acierta una proteína metagenómica que no se parecía a nada conocido.

POR QUÉ IMPORTA

- **14,2 s** para 384 residuos en una V100.
- Por eso se pudo hacer **a escala**.

	AlphaFold 2	ESMFold
Necesita MSA	Sí	No
Velocidad	Lento	Muy rápido
La señal	De los homólogos	Del PLM

Lin et al. (2023). *Evolutionary-scale prediction of atomic-level protein structure with a language model*. Science 379, 1123–1130 · Figuras 2A y 4 · PDF en [papers/esmfold.pdf](https://papers.eismfold.pdf)

ESM Atlas · el «lado oscuro» de las proteínas

Meta AI (2022). Si predecir estructura es tan rápido y no hace falta un alineamiento, se puede hacer **en masa**: predecir la estructura de *todo* lo que se ha secuenciado.

LA ESCALA DEL ATLAS

- **Más de 600 millones** de estructuras metagenómicas.
- La base más grande que existe: **3×** la mayor anterior.
- **2 semanas** en un clúster de **~2 000 GPUs**.
- Solo el **~10 %** con alta confianza — el resto es exploración.

Por qué se llama «lado oscuro»: son proteínas de microbios del suelo, del océano y de nuestro cuerpo. No se parecen a nada conocido, así que *no había forma de estudiarlas*. Ahora cada una tiene una estructura.

LO QUE CAMBIA

Antes: se elegía *una* proteína interesante y se le dedicaba un doctorado. Ahora: se predice el catálogo entero y **después** se busca qué mirar.

El cambio de método: la escala no es solo «más datos». Cambia *cómo se investiga* — de elegir un caso a explorar un espacio. Es el mismo salto que Foldseek habilita del otro lado: buscar estructura, no secuencia.

Meta AI (2022). *ESM Metagenomic Atlas: The first view of the 'dark matter' of the protein universe* · esmatlas.com · ai.meta.com/blog/protein-folding-esmfold-metagenomics

La forma se vuelve texto



Si la estructura se escribe con letras, un modelo de lenguaje **la puede leer**.

La forma se vuelve texto



Si la estructura se escribe con letras, un modelo de lenguaje **la puede leer**.


Paréntesis · Foldseek y la idea del 3Di

Antes de ProstT5 hubo un problema práctico: hay **cientos de millones** de estructuras predichas (214 M AlphaFoldDB + 617 M ESM Atlas). Compararlas era el cuello de botella.

La idea: si puedo *escribir la forma con letras*, puedo comparar estructuras con algoritmos de **secuencia**, optimizados por décadas.

CÓMO SE DISCRETIZA

- 10 rasgos geométricos por residuo
- Se agrupan en **20 estados**
- Un símbolo por residuo → una «secuencia» de forma



El 3Di describe el contacto entre un residuo y el más cercano en el espacio.

Por qué importa: dos proteínas pueden tener secuencias totalmente distintas y aun así *la misma forma*. Comparando forma se detectan parentescos que la secuencia sola ya no ve.

van Kempen et al. (2024), *Fast and accurate protein structure search with Foldseek*, Nature Biotechnology 42:243–246 ·

search.foldseek.com

Foldseek · el resultado

10^4 – 10^5 ×

más rápido que los
alineadores estructurales clásicos

- **>4 000×** más rápido que TM-align y Dali
- **>21 000×** más rápido que CE
- Hasta **180 000×** en bases grandes

Y sin perder sensibilidad: **86 %** de Dali, **88 %** de TM-align, y **133 %** de CE.

Por qué es tan rápido: no compara geometría, compara *texto*. Convierte un problema carísimo en uno que ya sabíamos resolver rápido.

Ese alfabeto 3Di es justamente el que **ProstT5** reutiliza en la slide siguiente. Foldseek lo inventó; ProstT5 lo aprendió.

ProstT5 · cuando la estructura se vuelve texto

Los modelos anteriores leen *solo* la secuencia. Pero una proteína también es una estructura 3D. ¿Se puede escribir la forma con letras?

OTRA VEZ, 20 LETRAS

El alfabeto **3Di** de Foldseek. Como usa 20 símbolos, un PLM lo lee *sin cambiar de arquitectura*.

TRADUCCIÓN EN DOS SENTIDOS

<AA2fold>

secuencia → forma

<fold2AA>

forma → secuencia

LO QUE APORTA

Buscar por **forma** encuentra parentescos que la secuencia ya no ve.




Figura 1 del paper: arquitectura (izq.), preentrenamiento en dos etapas (arriba der.) e inferencia (abajo der.).

Ojo con los nombres: **ProtT5** lee secuencia (1D); **ProstT5** lee secuencia y estructura (3D).

Qué se gana al traducir

SECUENCIA → ESTRUCTURA

Predecir el 3Di de una proteína *sin* calcular su estructura, y buscar con eso.

×1000 más rápido que extraer el 3Di de una estructura predicha.

ESTRUCTURA → SECUENCIA

Inverse folding: proponer secuencias que adopten una forma dada.

Diseño guiado por la forma, no por la secuencia.

El resultado más fuerte: el 3Di predicho es tan bueno que, pasado a Foldseek, detecta **homología remota** — proteínas muy divergentes con la misma forma— casi al nivel de usar estructuras experimentales.

Esto es lo que usa el trabajo de **Juan Diego Puglia** (ORT): ESM-C y **ProstT5** para representar proteínas, más un clasificador clásico.

Sin MSA y sin predecir coordenadas 3D: la señal estructural ya está en los embeddings.

Phold · cuando la estructura anota genomas

Un caso real que combina **exactamente** las dos piezas de las diapositivas anteriores: **ProstT5** (secuencia → 3Di) y **Foldseek** (buscar por forma). Bouras et al. (2026), *Nucleic Acids Research* 54:gkaf1448.

EL PROBLEMA

Anotar genomas de **bacteriófagos**: los virus más abundantes del planeta, y los más difíciles de anotar. Evolucionan tan rápido que **más del 65 %** de sus proteínas no se pueden anotar por homología de secuencia.

CÓMO LO RESUELVE

1. ProstT5 genera *embeddings* de 1024 dimensiones por residuo (encoder de 1000 millones de parámetros).
2. Una CNN de dos capas predice el **token 3Di** de cada residuo.
3. Foldseek busca esa «secuencia de forma» contra una base de **1,36 millones** de estructuras predichas.

EL RESULTADO

Sobre 16 460 CDS de fagos, porcentaje anotado:

MMseqs2 (secuencia)	34,7 %
PyHMMER (perfil HMM)	37,7 %
Phold (estructura)	49,4 %

Y con estructuras de ColabFold sube a **51,5 %**.

Lo que demuestra: la forma conserva señal que la secuencia ya perdió. Los fagos con más anotación son justamente los de *metabolismo de ácidos nucleicos* y funciones enzimáticas.

Por qué está en esta clase: es el mismo hallazgo de la diapositiva 39 llevado a producción — sin MSA y sin predecir coordenadas 3D, un PLM más un buscador de formas resuelve un problema real. Código abierto en github.com/gbouras13/phold.

MÓDULO 7 · SECUENCIA, ESTRUCTURA Y FUNCIÓN

Todo junto



Secuencia, estructura y función en **un mismo modelo**.

MÓDULO 7 · SECUENCIA, ESTRUCTURA Y FUNCIÓN

Todo junto



El siguiente salto · ESM3

Si ProstT5 une *dos* modalidades, ESM3 une **tres** en un mismo vocabulario.

SECUENCIA Las 20 letras	ESTRUCTURA Coordenadas 3D como tokens	FUNCIÓN Palabras clave, sitios catalíticos
-----------------------------------	---	--

98 000 millones de parámetros · más de **10²⁴** FLOPS. Un orden de magnitud más grande que ESM-2.

Se enmascara todo y se rellena posición por posición. El diseño se puede *guiar* dando parte de la secuencia, de la estructura o una palabra de función.




Figura 1B. Las tres pistas entran como *tokens discretos* y se fusionan en un solo espacio latente. El primer bloque lleva **atención geométrica**, que permite condicionar por coordenadas atómicas. ESM3 se entrena para predecir los tokens enmascarados.

Hayes et al. (2025). *Simulating 500 million years of evolution with a language model*. Science · github.com/evolutionaryscale/esm

esmGFP · una proteína que no existía

Se le dio *solo* la estructura de los residuos del núcleo de una GFP natural. ESM3 razonó en cadena, probó **96** generaciones y encontró proteínas que **fluorescen de verdad**.

≈ **500 millones**
de años, equivalentes




Figura 4A. El **prompt** (rojo): la secuencia y estructura de los residuos que forman y catalizan el cromóforo. El modelo generó **el resto** (azul).




Figura 4B. Fluorescencia medida en lisado de *E. coli*. Arriba las placas, abajo la cuantificación. Desde el pocillo **B8** (57 % de identidad) siguió la cadena hasta **C10**: esmGFP (**58 %**, 96 mutaciones sobre 229 aminoácidos).

Matiz importante: no es que el modelo «sepa» biología. Simula evolución porque *predecir el token enmascarado* lo obliga a aprender cómo se mueve la evolución en el espacio de proteínas posibles.

¿Qué aprende de las secuencias sin etiquetar?

Se entrena **solo** con secuencias sin etiquetar. Nadie le dice qué es la hidrofobicidad. Y sin embargo aprende...

Propiedades biofísicas — hidrofobicidad, carga, peso · **estructura secundaria** — hélices y láminas · **contactos 3D** — qué residuos están cerca.

Por qué funciona: la evolución ya resolvió el problema. Las secuencias que existen son las que *se pliegan y funcionan*. El modelo absorbe esas restricciones sin que nadie se las explicite.





Figura 2A. Fidelidad al prompt, panel por panel. El eje vertical es siempre la confianza de la estructura predicha (*ESMFold pTM*); el horizontal cambia en cada caso —y ojo: en unos más es mejor y en otros menos es mejor. **Structure coordinates** (cRMSD, *menos* es mejor): la densidad se apila arriba a la *izquierda*. **Secondary Structure** (accuracy, *más* es mejor): arriba a la derecha, con cola hacia abajo. **SASA** (Spearman ρ): es *bimodal* —un núcleo arriba a la derecha y buena parte de la masa abajo, con pTM bajo. **Keywords** (recuperación): se concentra en los *dos bordes*, casi nada en el medio. El mensaje no es un patrón único, sino que **promptear por estructura funciona muy bien** (cRMSD bajo con pTM alto) y que SASA y palabras clave son las pistas más flojas.

Un caso de aplicación

predecir dónde actúa una proteína

¿Dónde actúa la proteína?

Entrada — embeddings de ESM-C o ProstT5 · **Clasificador** — Random Forest o SVM · **Etiquetas** — PSORTdb.



El flujo. La secuencia entra por **tres** modelos (ProstT5 y dos tamaños de ESM-C), los *embeddings* resultantes alimentan clasificadores clásicos (RF y SVM), se evalúan y recién ahí se arma la interfaz.

No hace falta entrenar un modelo gigante: un PLM ya entrenado *más* un clasificador clásico resuelve el problema.

ENTRENAR LOS CLASIFICADORES

Columna	Qué trae
ID	identificador
RefSeq_Accession	acceso NCBI
Experimental_Localization	la etiqueta : <i>Cytoplasmic</i> , <i>Extracellular</i> ...

Fuente: **ePSORTdb 4.0** (localización medida en laboratorio) · archivo `ePSORTdb.tsv`
11.781 entradas · se descartan las de ubicación múltiple

EVALUAR LOS CLASIFICADORES

Conjunto	Proporción
Entrenamiento	67 %
Evaluación (test)	33 %

Partición con `train_test_split` de scikit-learn, *estratificada* (`stratify=y`) para conservar la proporción de clases.
Así el modelo se mide sobre datos que **nunca vio**.

De dónde salen las etiquetas. El conjunto sale de **ePSORTdb** — localización determinada *experimentalmente* —; de ahí se separa una parte para entrenar y otra para evaluar.

Es el trabajo de tesis de **Juan Diego Puglia** (ORT).

Los resultados · funciona, y con modelos chicos

Embeddings **congelados** + un clasificador clásico, sobre **11.781** proteínas bacterianas con localización medida en laboratorio.

PUNTAJE F1 EN EL CONJUNTO DE PRUEBA

Clasificador	F1 ponderado
SVM	96,02 %
Random Forest	94,50 %

Los dos pasaron el 90 % con *todos* los modelos de lenguaje probados.
El mejor: **ESM-C 300m**.

El contraste que importa: un clasificador clásico sobre embeddings congelados saca **96 %**. No hizo falta entrenar nada grande — hizo falta el vector adecuado.

DÓNDE ACIERTA Y DÓNDE NO

- **Cytoplasmic** — 98 % de verdaderos positivos, la clase más fácil (es el 61 % del dataset).
- **Cellwall** — 83 %.
- **Periplasmic** — 82 %, y la más difícil: es solo el **0,93 %** de los datos.

El error se concentra en las clases minoritarias: no es que el modelo no sepa, es que hay pocos ejemplos.

Y quedó usable: una interfaz gráfica en Python donde se pega una secuencia en FASTA y devuelve la localización. Está publicada en

`huggingface.co/jpuglia/ProteinLocationPredictor`.

Tesis de **Juan Diego Puglia** (ORT) · Random Forest y SVM sobre embeddings de ESM-C 300m/600m y ProstT5 · métrica: F1 *ponderado* sobre el 33 % de prueba.

¿Más grande, o mejor diseñado?

LA NARRATIVA DEL *SCALING*

- Más parámetros → representaciones más ricas
- Tendencia dominante
- Cuesta cómputo, dinero y energía

ANKH: EL CONTRAPUNTO

- Optimiza para proteínas en vez de escalar
- Estado del arte con **<10%** de parámetros
- **<7%** inferencia · **<30%** dimensión

La accesibilidad importa: un modelo que corre en hardware modesto democratiza la investigación.

Elnaggar et al., arXiv:2301.06568

Lo que estos modelos *no* hacen

No «entienden» biología. Aprenden correlaciones estadísticas de la evolución. No simulan física, ni química, ni termodinámica.

Situación	Qué pasa
Proteína sin homólogos conocidos	Poco de dónde aprender
Mutación que cambia la física	Puede no anticiparla
Condiciones <i>in vivo</i> reales	Fuera de su alcance

Un buen *score in silico* es una **hipótesis**, no un resultado.

De la laptop al supercómputo

USAR UN PLM

- Pesos preentrenados (HuggingFace)
- Inferencia en una GPU de consumo
- **Accesible hoy**

ENTRENAR UN PLM

- Miles de GPU-hora
- Clusters especializados
- Barrera real de entrada

Entrenar es de pocos; **usar es de casi todos**. Ahí es donde podés aportar hoy.

Tres ideas para llevarse

- 1 Una proteína es texto en 20 símbolos, y su gramática conecta posiciones lejanas.**
- 2 Un embedding vuelve geometría el significado; el contexto reescribe el vector.**
- 3 Los PLMs aprenden evolución acumulada, no física. La mesada sigue mandando.**

Para seguir explorando

Revisiones

- Pérez-Villanueva et al. (2026). *Descifrando el Lenguaje de las Proteínas*. TIES, UNAM
- Leclercq & Droit (2025). *Protein Language Models*. J. Proteome Res.
- Elnaggar et al. (2023). *Ankh*. arXiv:2301.06568
- Heinzinger et al. (2024). *ProstT5: bilingual sequence–structure*. NAR Genom. Bioinform. 6(4), lqae150
- van Kempen et al. (2024). *Foldseek: fast and accurate protein structure search*. Nat. Biotechnol. 42:243–246
- Hayes et al. (2025). *ESM3*. Science · evolutionaryscale.ai/blog/esm3-release

Para seguir explorando · modelos

Modelos

- ESM / ESM-2 / ESMFold — huggingface.co/facebook
- ESM-C — huggingface.co/EvolutionaryScale
- ESM3 (1.4B abierto, MIT) — github.com/evolutionaryscale/esm
- ProtT5 / ProtBERT — huggingface.co/Rostlab
- **ProstT5** (secuencia + estructura) — huggingface.co/Rostlab/ProstT5
- ProtGPT2 — huggingface.co/nferruz · ZymCTRL — huggingface.co/AI4PD
- Foldseek (alfabeto 3Di) — search.foldseek.com

Caso aplicado

- AggrescanAI — gitlab.com/bioinformatics-fil/aggrescanai

